UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO
CENTRO UNIVERSITÁRIO NORTE DO ESPÍRITO SANTO(CEUNES)
DEPARTAMENTO DE COMPUTAÇÃO E ELETRÔNICA(DCEL)
CURSO DE GRADUAÇÃO EM ENGENHARIA DA COMPUTAÇÃO

GABRIEL MARTINS SPÓSITO

Aplicação de métodos de Mineração de Dados sobre os dados abertos do ENEM de 2023

São Mateus - ES

2025

GABRIEL MARTINS SPÓSITO

Aplicação de métodos de Mineração de Dados sobre os dados abertos do ENEM de 2023

Monografia apresentada ao Colegiado do Curso de Engenharia de Computação do Centro Tecnológico da Universidade Federal do Espírito Santo, como requisito parcial para obtenção do Grau de Bacharel em Engenharia de Computação.

Orientador(a): Profª. Dra. Silvia das Dores Rissino

São Mateus - ES

2025

RESUMO

A crescente produção de dados educacionais no Brasil tem impulsionado o uso de métodos estatísticos e técnicas avançadas de mineração de dados para identificar tendências e desigualdades no sistema educacional. Este projeto tem como objetivo analisar o perfil dos participantes do Exame Nacional do Ensino Médio (Enem) 2023 em nível nacional, comparando estudantes de escolas públicas e privadas. Para isso, serão utilizados dados socioeconômicos e de desempenho disponibilizados em bases abertas do Ministério da Gestão e Inovação e do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep). Após etapas de seleção, limpeza, pré-processamento e transformação dos dados, serão aplicadas técnicas de clustering e análise de agrupamentos para identificar perfis distintos de estudantes, considerando variáveis socioeconômicas, características escolares e desempenho nas áreas avaliadas pelo exame. Espera-se que os perfis resultantes evidenciem diferenças estruturais entre redes pública e privada, contribuindo para uma compreensão mais profunda das desigualdades educacionais no país.

Palavras-chave: Mineração de Dados, KDD, Enem 2023, Escolas Públicas, Espírito Santo.

ABSTRACT

The increasing production of educational data in Brazil has driven the use of statistical methods and data mining techniques to identify trends and inequalities in the education system. This project aims to analyze the profile of participants in the 2023 National High School Exam (Enem) nationwide, comparing students from public and private schools. To this end, socioeconomic and performance data available in open databases from the Ministry of Management and Innovation and the National Institute of Educational Studies and Research Anísio Teixeira (Inep) will be used. After data selection, cleaning, preprocessing, and transformation stages, clustering and cluster analysis techniques will be applied to identify distinct student profiles, considering socioeconomic variables, school characteristics, and performance in the areas assessed by the exam. It is expected that the resulting profiles will highlight structural differences between public and private networks, contributing to a deeper understanding of educational inequalities in the country. **Keywords**: Data Mining, KDD, Enem 2023, Public Schools, Espírito Santo.

LISTA DE FIGURAS

Figura 1 – Processo de Descoberta de Conhecimento em Bases de Dados (KDD)..13
Figura 2 – Modelos e Funções de Mineração de Dados.....14
Figura 3 – Análise comparativa — K-Means *Clustering*.....29
Figura 4 – Análise comparativa — Regressão Linear 32
Figura 5 – Análise comparativa — Random Forest (com variáveis consolidadas).....33
Figura 6 – Análise comparativa — Árvore de Decisão 33

LISTA DE QUADROS

Quadro 1 – Características da máquina utilizada.....19
Quadro 2 – Valores dos Clusters*(continua)* 30
Quadro 3 – Top 5 regras gerais para Base de Escolas Públicas.....34
Quadro 4 – Top 5 regras gerais para Base de Escolas Privadas 34

SUMÁRIO

1 INTRODUÇÃO 10
1.1 Considerações Gerais 10
1.2 Objetivo Geral 11
1.3 Objetivo Específicos 11
1.4 Organização do trabalho 11

2 REFERENCIAL TEÓRICO 12
2.1 Bases de dados abertas 12
2.2 Processo de Descoberta de Conhecimento em Bases de Dados 12
2.3 Técnicas e Modelos de Mineração de Dados 14
2.3.1 Algoritmos Descritivos 14
2.3.2 Algoritmos Preditivos 15
2.4 Linguagem de Programação Python 16
2.5 Trabalhos Relacionados 17

3 METODOLOGIA 18
3.1 Ferramentas utilizadas 18
3.1.1 Ambiente de desenvolvimento 18
3.1.2 Linguagem de Programação e Bibliotecas 18
3.1.3 Especificações de Máquina 18
3.2 Ambiente dos Dados 19
3.2.1 Descrição das Variáveis 19
3.3 Pré-processamento 20
3.4 Transformação dos Dados 21
3.5 Mineração de Dados 22
3.5.1 Regras de Associação 22
3.5.2 Agrupamento 23
3.5.3 Classificação 23
3.5.4 Regressão logística 24
3.5.5 Algoritmos 24
3.5.5.1 Apriori e FP-Growth 25
3.5.5.2 Decision Tree Regressor 26
3.5.5.3 Random Forest 26
3.5.5.4 Regressão Linear 26
3.5.5.5 K-Means 26
3.5.6 Pós-Processamento 27

4 RESULTADOS **28**

5 CONCLUSÃO **34**

5.1 Considerações Finais **34**

5.2 Trabalhos Futuros **35**

REFERÊNCIAS **36**

ANEXO A – DICIONÁRIO DE DADOS **39**

1 INTRODUÇÃO

1.1 Considerações Gerais

Os avanços na área de Tecnologia da Informação (TI) têm gerado grandes volumes de dados em diversas áreas, incluindo a saúde. Nesse vasto conglomerado de dados produzidos diariamente, é possível identificar padrões, regras, tendências e diversos relacionamentos sistemáticos. Com o crescente aumento da disponibilidade de dados na sociedade atual, as bases de dados públicas abertas tornaram-se fontes valiosas de informação para pesquisadores e profissionais de todas as áreas.

Gerar conhecimento a partir dessa abundância de dados requer o uso de metodologias apropriadas, como o Processo de Descoberta de Conhecimento em Bases de Dados (do inglês, *Knowledge Discovery in Databases* – KDD), mais conhecido pela sigla KDD. Trata-se de um processo iterativo e interativo que abrange etapas como a preparação dos dados, a busca por padrões, a avaliação dos resultados e o refinamento dos mesmos (Dhaenens; Jourdan, 2019).

O KDD utiliza bases de dados para realizar a seleção de atributos e as transformações necessárias (pré-processamento), aplicar métodos ou algoritmos de Mineração de Dados (MD) para extrair padrões e avaliar os resultados da MD, identificando padrões que possam ser considerados conhecimento (pós-processamento).

Para as instituições, o reconhecimento de padrões pode aprimorar estratégias de marketing, personalizar o atendimento e fortalecer o relacionamento com os consumidores, entre outros benefícios. Já para entidades públicas, os conhecimentos obtidos por meio desse processo de exploração de dados podem embasar ações sociais e políticas, além de contribuir para a mitigação de problemas de saúde pública, como endemias e epidemias. A mineração de dados, como disciplina, combina técnicas de aprendizado de máquina, estatística e visualização de dados para revelar informações ocultas e padrões significativos, permitindo a extração de conhecimento útil a partir de grandes volumes de dados complexos e não estruturados. Assim, torna-se uma ferramenta indispensável na área da saúde (Sergio; Silva; Gonçalves, 2016).

A Mineração de Dados Educacionais (*Educational Data Mining* – EDM) é uma área científica emergente que se dedica à aplicação de técnicas de mineração de dados para explorar grandes conjuntos de dados provenientes de escolas e universidades. Seu objetivo é compreender o contexto em que ocorrem a aprendizagem e outras questões educacionais (Baker, 2010; Romero; Ventura, 2007).

No Brasil, o governo disponibiliza diariamente na web dados em formato aberto e sob licença de dados abertos. Nesse contexto, este projeto considera a proposta de dados

abertos do Ministério da Gestão e da Inovação em Serviços Públicos, que define dados abertos como aqueles que podem ser livremente acessados, utilizados, modificados e compartilhados para qualquer finalidade (Brasil. Ministério da Gestão e da Inovação em Serviços Públicos, 2022).

1.2 Objetivo Geral

O objetivo geral deste trabalho de Iniciação Científica é analisar a aplicação de técnicas e modelos de mineração de dados em bases de dados abertas, com foco em fontes governamentais, a fim de identificar boas práticas para a extração de padrões e conhecimentos relevantes. Para alcançar tal propósito, o percurso metodológico inicia-se com uma revisão bibliográfica abrangente sobre os fundamentos do processo de Descoberta de Conhecimento em Bases de Dados (KDD) e das principais técnicas de mineração. Subsequentemente, será realizada a prospecção e a avaliação das características de bases de dados abertas, em especial as governamentais, considerando aspectos como volume, formato e qualidade.

1.3 Objetivo Específicos

A aplicação de técnicas de descoberta de conhecimento em bases de dados (KDD) no Enem 2023 pode revelar padrões relevantes sobre o perfil dos estudantes brasileiros, permitindo uma comparação estruturada entre alunos das redes pública e privada. Essa análise possibilita identificar fatores associados ao desempenho no exame, assim como compreender a distribuição geográfica, o contexto socioeconômico e outras variáveis que influenciam os resultados obtidos. A interpretação desses padrões contribuirá para a identificação das variáveis mais determinantes no desempenho dos estudantes.

1.4 Organização do trabalho

O trabalho está organizado em cinco seções. Na Seção 1, é apresentada a introdução ao tema do trabalho. Na Seção 2, é feito um levantamento bibliográfico sobre as etapas do KDD, sobre mineração de dados educacionais e apresenta alguns trabalhos relacionados ao tema. A Seção 3 descreve a metodologia aplicada ao trabalho. Na Seção 4, são exibidos os resultados obtidos nas etapas do KDD utilizando o Python. E na Seção 5, é descrita a conclusão e trabalhos futuros.

2 REFERENCIAL TEÓRICO

2.1 Bases de dados abertas

Bases de dados abertas são conjuntos de dados disponibilizados ao público de forma livre, em formatos que permitem seu acesso, reutilização e redistribuição, preferencialmente de maneira automatizável. Em geral, uma base de dados aberta apresenta as seguintes características: (i) acesso público e gratuito, sem barreiras legais ou tecnológicas excessivas; (ii) disponibilização em formatos estruturados e legíveis por máquina (por exemplo, CSV, JSON ou XML); (iii) documentação mínima, incluindo dicionário de dados e descrição das variáveis; e (iv) licença clara que autoriza o uso, a análise e a divulgação de resultados derivados, respeitando a legislação de proteção de dados pessoais e o anonimato dos participantes.

No contexto educacional brasileiro, um exemplo relevante de base de dados aberta são os microdados do Exame Nacional do Ensino Médio (Enem). Em particular, os microdados do Enem são disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) em plataforma oficial do Governo Federal, em formato CSV, acompanhados de documentação técnica e dicionário de variáveis. Esses microdados contêm informações anonimizadas sobre os participantes, incluindo dados socioeconômicos, características das escolas e notas obtidas nas provas objetivas e na redação.

A natureza aberta dessa base permite que pesquisadores, gestores públicos e demais interessados a utilizem para diferentes finalidades, tais como: análise estatística descritiva, estudos de correlação entre desempenho e perfil socioeconômico, aplicação de técnicas de mineração de dados e *machine learning*, e avaliação de políticas públicas em educação. No presente trabalho, os microdados do Enem 2023 são empregados como fonte principal de informação, justamente por se tratarem de uma base de dados aberta, padronizada e amplamente reconhecida, o que favorece a reprodutibilidade e a comparabilidade dos resultados.

2.2 Processo de Descoberta de Conhecimento em Bases de Dados

O Processo de Descoberta de Conhecimento em Bases de Dados (KDD) é composto por diversas etapas que visam extrair conhecimento útil a partir de grandes conjuntos de dados. A seguir, apresenta-se uma descrição das principais etapas, conforme ilustrado na Figura 1:

- **Etapa de Seleção:** Refere-se ao banco de dados ou conjunto de dados que será

Figura 1 – Processo de Descoberta de Conhecimento em Bases de Dados (KDD).

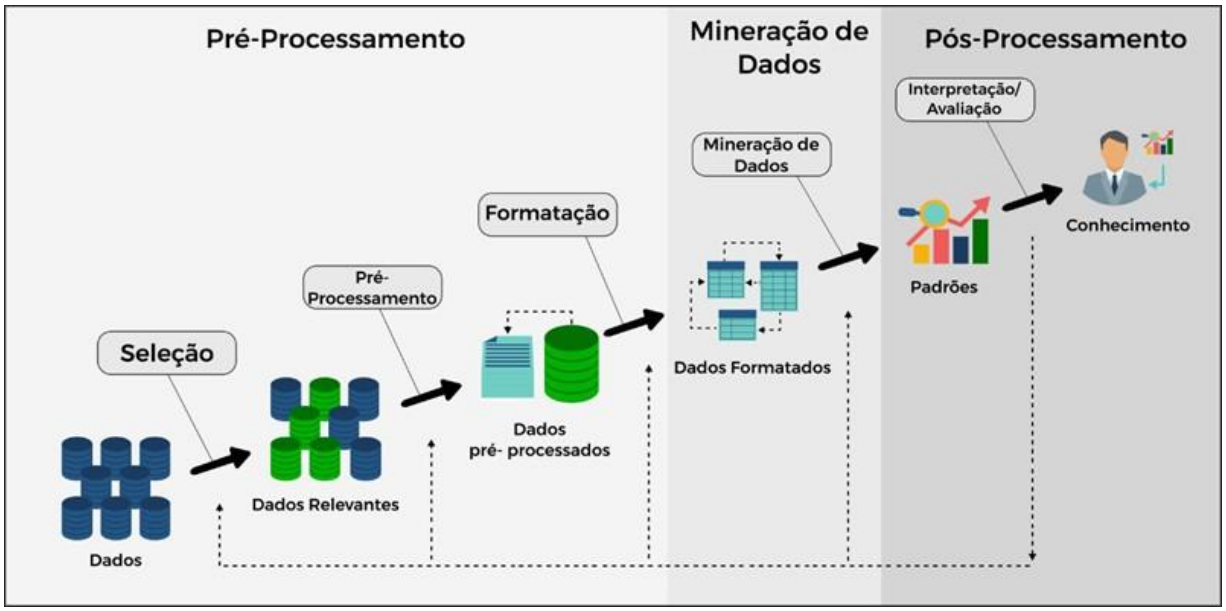

Fonte: Adaptado de (Fayyad; Piatetsky-Shapiro; Smyth, 1996).

utilizado na descoberta de conhecimento, acompanhado, quando disponível, de um levantamento bibliográfico para obter informações ou planejar ações em uma área específica. Nesta etapa, com os dados coletados, é necessário focar em um subconjunto de variáveis ou amostras, eliminando aquelas que não serão usadas para otimizar o tempo de processamento e reduzir o tamanho do arquivo (Fayyad; Piatetsky-Shapiro; Smyth, 1996).

- **Pré-processamento:** Dados coletados por humanos frequentemente contêm erros, como campos trocados ou tipos incorretos (ex.: *floats* em vez de *integers*, *strings* no lugar de números). Aqui, concentram-se na identificação e tratamento de dados ausentes ou ruidosos, que podem ser removidos ou transformados (Palacios *et al.*, 2021).

- **Formatação:** Envolve o dimensionamento das variáveis e uma verificação adicional para corrigir possíveis erros não detectados nas etapas anteriores, além de padronizar os dados para a próxima fase. Nesta etapa, também é possível gerar novas variáveis a partir das existentes (Palacios *et al.*, 2021).

- **Mineração de Dados:** Com os dados formatados e uma área de aplicação definida (ex.: marketing, saúde, educação), utiliza-se o conhecimento das técnicas levantadas na etapa inicial para buscar padrões de interesse. Esses padrões, representados por regras de classificação, árvores, regressão ou agrupamentos, devem ser claros, compreensíveis e precisos (Fayyad; Piatetsky-Shapiro; Smyth, 1996).

- **Interpretação/Avaliação:** Realiza-se uma análise detalhada da qualidade dos padrões obtidos, com a possibilidade de retornar às etapas anteriores para refinamento, seja com novos dados ou ajustes em técnicas. Esta fase pode incluir a visualização dos padrões ou dos dados extraídos, auxiliando na tomada de decisões estratégicas na área em questão (Fayyad; Piatetsky-Shapiro; Smyth, 1996).

2.3 Técnicas e Modelos de Mineração de Dados

Na mineração de dados, as estratégias podem visar a descoberta de padrões ou a previsão de informações futuras, resultando em duas categorias principais: descritiva e preditiva, conforme ilustrado na Figura 2. A categoria descritiva busca identificar padrões ocultos nos dados, enquanto a preditiva utiliza dados atuais para prever eventos futuros (Han; Kamber, 2006).

Essas categorias abrangem técnicas como caracterização e discriminação, mineração de padrões frequentes, associações e correlações, classificação e regressão, análise de agrupamento e detecção de *outliers* (Han; Kamber, 2006). A seguir, são apresentados os algoritmos mais comuns em cada categoria:

Figura 2 – Modelos e Funções de Mineração de Dados.

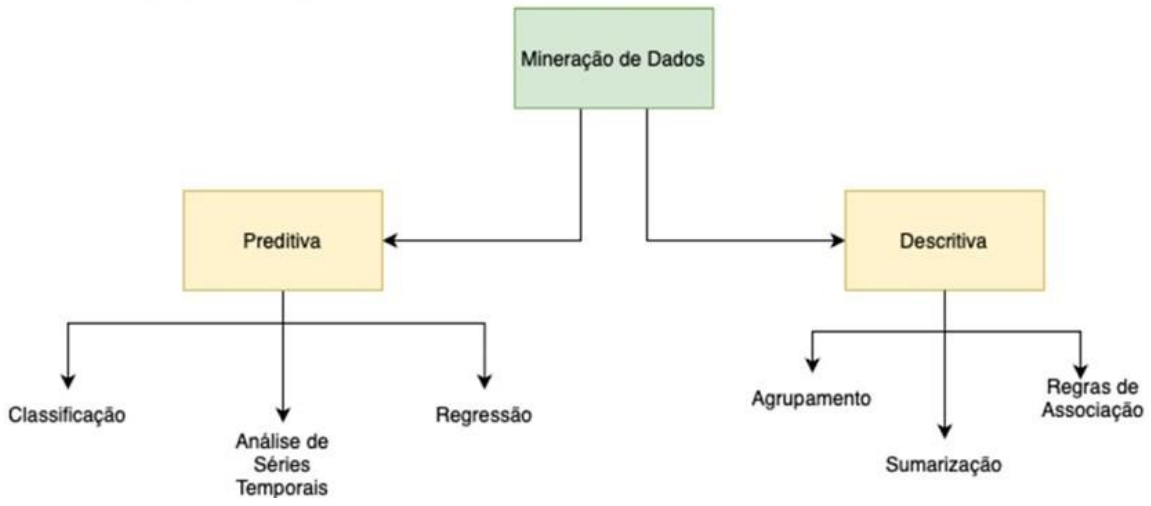

Fonte: Próprio autor.

2.3.1 Algoritmos Descritivos

- **Regras de Associação:**
  - *Apriori*: Identifica padrões frequentes em bases transacionais (ex.: cestas de compras) usando suporte (frequência) e confiança (relação entre itens) (Agrawal; Srikant, 1994).

  - *FP-Growth*: Alternativa mais eficiente ao *Apriori*, utiliza uma estrutura em árvore (*FP-Tree*) para armazenar padrões frequentes (Han; Pei; Yin, 2000).

- **Agrupamento:**
  - *K-Means*: Divide os dados em *k clusters* com base em similaridade, sendo sensível à escolha inicial de *k* (Macqueen, 1967).
  - *DBSCAN*: Identifica *clusters* baseados em densidade, definindo regiões densas e detectando *outliers* automaticamente (Ester *et al.*, 1996).

- **PCA (Análise de Componentes Principais):** Reduz a dimensionalidade dos dados, transformando variáveis correlacionadas em componentes ortogonais (Jolliffe, 2002).

- **Detecção de Anomalias:**
  - *LOF (Local Outlier Factor)*: Detecta anomalias com base na densidade local dos dados (Breunig *et al.*, 2000).

- **Mineração de Textos:**
  - *TF-IDF (Term Frequency-Inverse Document Frequency)*: Calcula a relevância de palavras em documentos (Salton; Buckley, 1988).
  - *LDA (Latent Dirichlet Allocation)*: Modela tópicos em textos, identificando estruturas latentes (Blei; Ng; Jordan, 2003).

2.3.2 Algoritmos Preditivos

- **Classificação:**
  - *Árvores de Decisão*: Modelos interpretáveis baseados em uma estrutura de árvore (Quinlan, 1986).
  - *SVM (Support Vector Machines)*: Encontra um hiperplano ótimo para separar classes (Cortes; Vapnik, 1995).
  - *KNN (K-Nearest Neighbors)*: Classifica pontos com base nos *k* vizinhos mais próximos (Cover; Hart, 1967).
  - *Redes Neurais (ANN)*: Inspiradas no cérebro humano, eficazes em problemas complexos (Goodfellow; Bengio; Courville, 2016).
  - *Random Forest*: Combina múltiplas árvores de decisão para maior precisão (Breiman, 2001).

- **Regressão:**

  Regressão Linear: Prediz valores contínuos com um modelo linear $y = \beta_0 + \beta_1 x + \varepsilon$ (Draper; Smith, 1998).

  – *Regressão Logística*: Prevê probabilidades usando a função sigmoide $P(y = 1) = \frac{1}{1+e^{-z}}$ (Hosmer; Lemeshow, 2000).

  – *Árvores de Regressão*: Variante das árvores de decisão para valores contínuos (Quinlan, 1986).

- **Séries Temporais:**

  – *ARIMA*: Combina componentes autorregressivos, integração e média móvel para séries estacionárias (Box *et al.*, 2016).

  – *Prophet*: Desenvolvido pelo Facebook, ajusta séries com sazonalidade (Taylor; Letham, 2018).

  – *RNN (Redes Neurais Recorrentes)*: Trata dados sequenciais, com destaque para *LSTM* (Hochreiter; Schmidhuber, 1997).

2.4 Linguagem de Programação Python

Python é uma linguagem de programação que permite trabalhar de forma rápida e integrar sistemas eficientemente (Python Software Foundation, 2024). É amplamente utilizada em análise de dados por ser fácil de aprender e de código aberto (*open source*), possibilitando que usuários implementem funções personalizadas. Contudo, atualizações em bibliotecas podem gerar falhas em cascata caso parâmetros ou nomes sejam alterados (Behrman, 2023).

As principais bibliotecas utilizadas neste projeto incluem:

- **Pandas:** Ferramenta de código aberto para manipulação e análise de dados, rápida e flexível, construída sobre Python (The Pandas Development Team, 2020).
- **NumPy:** Pacote fundamental para computação científica, oferecendo suporte a *arrays* multidimensionais e operações matemáticas eficientes (Harris *et al.*, 2020).
- **SciPy:** Coleção de algoritmos matemáticos baseada em NumPy, voltada para manipulação e visualização de dados (Virtanen; Oliphant; Gommers, 2020).
- **Scikit-learn:** Módulo que integra algoritmos de aprendizado de máquina para problemas supervisionados e não supervisionados (Pedregosa *et al.*, 2011).
- **Seaborn:** Biblioteca de visualização baseada em Matplotlib, focada em gráficos estatísticos informativos (Waskom, 2021; Hunter, 2007).

2.5 Trabalhos Relacionados

O trabalho *Knowledge Discovery for Higher Education Student Retention Based on Data Mining: Machine Learning Algorithms and Case Study in Chile* previu a retenção dos alunos em cada um dos três níveis durante o primeiro, segundo e terceiro anos de estudo, obtendo modelos com precisão superior a 80% em todos os cenários. Este estudo demonstrou que a pontuação educacional secundária e o índice de pobreza comunitária são variáveis preditivas importantes (Palacios *et al.*, 2021).

Outro estudo *Educational Data Mining: A Bibliometric Analysis of an Emerging Field*, que se concentra principalmente no uso de técnicas de EDM de última geração para otimizar modelos de previsão, prever com precisão o desempenho acadêmico dos alunos e detectar comportamentos dos alunos para intervenção oportuna. Além disso, o estudo demonstra que a maioria dos artigos envolve investigações sobre EDM na pedagogia e nos contextos de aprendizagem (Baek; Doleck, 2022).

Outro estudo voltado para os benefícios da mineração de dados educacionais é o de A. B. Zoric, *Benefits of Educational Data Mining*, no qual a autora explora as implicações que essa mineração pode ter sobre as instituições e alunos, melhorando o suporte ao ensino, bem como a tomada de decisões em sistemas educacionais. O estudo aborda aspectos como a criação de perfis de alunos, a identificação de problemas que levam à evasão e a previsão do desempenho dos alunos, entre outros (Zorić, 2020).

3 METODOLOGIA

3.1 Ferramentas utilizadas

3.1.1 Ambiente de desenvolvimento

O Jupyter Notebook é uma plataforma de computação interativa baseada na web com suporte para mais de 40 linguagens de programação, como o Python e o R. Esta ferramenta foi utilizada, em todas as etapas devido à sua característica de poder executar uma linha ou pedaço de código por vez, permitindo, assim, uma visualização e exploração mais dinâmica e eficiente da base de dados. Para a realização deste estudo, utilizou-se a versão 6.29.5 do Jupyter Notebook. O Visual Studio Code (VS-Code) é um ambiente de desenvolvimento integrado (do inglês, Integrated Development Environment, ou IDE) para a maioria das linguagens utilizadas atualmente. Esta ferramenta foi utilizada na aplicação dos algoritmos de mineração de dados, desde a etapa de Seleção a Mineração de dados e extração de informação. Para a realização deste estudo, utilizou-se a versão 1.103.1.

3.1.2 Linguagem de Programação e Bibliotecas

A linguagem de programação escolhida para o desenvolvimento deste trabalho foi o Python, que atualmente é uma das mais utilizadas tanto no mundo acadêmico quanto no mundo corporativo. É uma linguagem de programação de alto nível, cujo design enfatiza legibilidade de código e apresenta um sistema dinâmico que suporta diversos paradigmas de programação e um gerenciamento automático de memória. Além de ser uma linguagem simples, rápida, poderosa e portátil, é uma linguagem de código aberto (Python Software Foundation, 2024). As bibliotecas pandas e NumPy foram utilizadas desde a etapa de pré-processamento até a mineração dos dados. A NumPy oferece uma estrutura de dados para tratar dados numéricos, além de funções e ferramentas para manipular e processar essa estrutura. Já o pandas, uma das principais bibliotecas da linguagem no quesito de análise de dados, oferece estruturas de dados e funções para lidar com dados estruturados, permitindo simplicidade e eficiência na manipulação de base de dados oriundos de planilhas ou de base de dados relacionais (The Pandas Development Team, 2020).

3.1.3 Especificações de Máquina

Para a realização deste estudo, foi utilizada a máquina pessoal do autor para executar os códigos desenvolvidos em Python. As informações sobre o hardware e o sistema operacional dela são apresentadas no Quadro 1.

Quadro 1 – Características da máquina utilizada

Sistema Operacional	Processador	Placa de Vídeo	Memória RAM
Windows 11 **Pro** *Single Language x64* versão **25H2**	I5-13450HX	*NVIDIA GeForce RTX 3050 6 GB* Intel® HD Graphics	24 GB

Fonte: Produzida pelo autor.

3.2 Ambiente dos Dados

Originado em 1998 visando avaliar o desempenho dos alunos brasileiros encerrando o ciclo educacional básico, o Exame Nacional do Ensino Médio (ENEM) foi desenvolvido a ponto de substituir o vestibular como forma de ingresso nos cursos superiores de educação e, atualmente, qualquer pessoa que já finalizou ou está no ensino médio pode participar do exame. O exame é realizado todos os anos pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) buscando avaliar os participantes através da elaboração de uma redação e de 180 questões objetivas que abrangem quatro áreas de conhecimento: linguagens, códigos e suas tecnologias; ciências humanas e suas tecnologias; ciências da natureza e suas tecnologias; e matemática e suas tecnologias ((Inep), 2025).

3.2.1 Descrição das Variáveis

A seguir é apresentado uma pequena amostra do dicionário de dados do ENEM de 2023, a qual é encontrada no mesmo arquivo ZIP que contém a base de dados, e não houve nenhuma alteração ou correção ortográfica das informações obtidas. Nesta amostra tem-se os dados referentes aos dados da redação. O dicionário completo se encontra no Anexo A – Dicionário de Dados.

- **TP_STATUS_REDACAO**: Situação da redação do participante
  - 1 – Sem problemas
  - 2 – Anulada
  - 3 – Cópia do texto motivador
  - 4 – Em branco
  - 6 – Fuga ao tema
  - 7 – Não atendimento ao tipo textual
  - 8 – Texto insuficiente
  - 9 – Parte desconectada

- **NU_NOTA_COMP1**: Nota da competência 1 — Demonstrar domínio da modalidade escrita formal da Língua Portuguesa.
- **NU_NOTA_COMP2**: Nota da competência 2 — Compreender a proposta de redação e aplicar conceitos das várias áreas de conhecimento para desenvolver o tema, dentro dos limites estruturais do texto dissertativo-argumentativo em prosa.
- **NU_NOTA_COMP3**: Nota da competência 3 — Selecionar, relacionar, organizar e interpretar informações, fatos, opiniões e argumentos em defesa de um ponto de vista.
- **NU_NOTA_COMP4**: Nota da competência 4 — Demonstrar conhecimento dos mecanismos linguísticos necessários para a construção da argumentação.
- **NU_NOTA_COMP5**: Nota da competência 5 — Elaborar proposta de intervenção para o problema abordado, respeitando os direitos humanos.
- **NU_NOTA_REDACAO**: Nota total da prova de redação.

3.3 Pré-processamento

Inicialmente, os dados são carregados no software VS-Code para adequar os dados à codificação UTF-8 de modo a facilitar os próximos passos. Em seguida, realiza-se uma análise exploratória do banco de dados visando identificar o número de atributos presentes, seus tipos de dados, a quantidade de valores distintos neles, quais deles possuem valores ausentes e os valores mais comuns. O banco de dados possui **3.933.955 linhas** e **76 colunas**.

Com base nos resultados obtidos na análise exploratória e visando utilizar a maior quantidade possível de registros, foram removidos alguns atributos por diferentes motivos. Os atributos **NU_INSCRICAO**, **NU_ANO**, **TP_NACIONALIDADE**, **NU_NOTA_COMP1**, **NU_NOTA_COMP2**, **NU_NOTA_COMP3**, **NU_NOTA_COMP4**, **NU_NOTA_COMP5**, **SG_UF_PROVA, NO_MUNICIPIO_PROVA, CO_PROVA_CN, CO_PROVA_CH, CO_PROVA_LC, CO_PROVA_MT, TP_ANO_CONCLUIU, TP_COR_RACA, TP_ENSINO, TP_ESTADO_CIVIL, TP_LINGUA**, **TP_ST_CONCLUSAO** e **TP_STATUS_REDACAO** foram excluídos por não apresentarem informações relevantes para a análise.

Os atributos **TP_ENSINO**, **CO_MUNICIPIO_ESC**, **NO_MUNICIPIO_ESC**, **CO_UF_ESC**, **SG_UF_ESC**, **TP_ESTADO_CIVIL**, **TP_LOCALIZACAO_ESC** e **TP_SIT_FUNC_ESC** foram removidos devido à alta porcentagem de valores ausentes.

De forma semelhante, os atributos **TX_RESPOSTAS_CN**, **TX_RESPOSTAS_CH**, **TX_RESPOSTAS_LC**, **TX_RESPOSTAS_MT**, **TX_GABARITO_CN**, **TX_GABARITO_CH**, **TX_GABARITO_LC**, **TX_GABARITO_MT**, **CO_MUNICIPIO_PROVA** e **CO_UF_PROVA** foram removidos por apresentarem informações redundantes, já representadas em outras variáveis da base.

O atributo **IN_TREINEIRO**, que indica se o participante é um treineiro, foi removido os registros que identificava que o participante era treineiro, uma vez que o foco do estudo são os participantes regulares do exame. Logo em seguida, o atributo foi removido por não apresentar mais variação, ou seja, todos os registros restantes indicam que o participante não é um treineiro.

Os atributos **NU_NOTA_CN**, **NU_NOTA_CH**, **NU_NOTA_LC**, **NU_NOTA_MT** junto com **NU_NOTA_REDACAO** foram utilizados para calcular a MEDIA da nota total do exame de cada candidato, representada no atributo **NU_MEDIA_GERAL**, e, portanto, foram removidos para evitar redundância.

Após uma análise mais aprofundada sobre os motivos dos valores ausentes nas colunas relacionadas aos dados das provas objetivas e da redação, verificou-se que esses valores ocorrem exclusivamente para participantes que faltaram ao exame ou foram eliminados. Assim, ao remover os registros desses participantes, todos os valores ausentes nessas colunas foram eliminados. Consequentemente, as colunas referentes à presença nas provas tornaram-se irrelevantes e puderam ser removidas.

Quanto aos valores ausentes nas variáveis do questionário socioeconômico, como o percentual de ausência era muito pequeno, optou-se pela remoção direta desses registros, o que concluiu o tratamento de dados faltantes.

Ao final dessa etapa, a base de dados passou a conter **2.166.843 registros** e **30 colunas TP_FAIXA_ETARIA**, **TP_SEXO**, **Q01_Educacao_Pai**, **Q02_Educacao_Mae**, **Q03_Grupo_Ocupacao_Pai**, **Q04_Grupo_Ocupacao_Mae**, **Q05_Moradores/Residencia**, **Q06_Renda_Familiar_Mensal**, **Q07_Empregado_Domestico**, **Q08_Banheiro/Residencia**, **Q09_Quartos/Residencia**, **Q10_Carro/Residencia**, **Q11_Moto/Residencia**, **Q12_Geladeira/Res Q13_Freezer/Residencia**, **Q14_Maq_Lavar_Roupa/Residencia**,

Q15_Maq_Secar_Roupa/Resid **Q16_Micro-ondas/Residencia**, **Q17_Maq_Lavar_Louca/Residencia**, **Q18_Aspirador/Residenc** **Q19_TV/Residencia**, **Q20_DVD/Residencia**, **Q21_TV_Assinatura/Residencia**, **Q22_Celular/Res** **Q23_Telefone_Fixo/Residencia**, **Q24_PC/Residencia**, **Q25_Acesso_Internet**, **NU_MEDIA_GERAL** devidamente tratadas.

3.4 Transformação dos Dados

Nessa etapa, os atributos presentes na base de dados foram transformados de modo a adaptá-los aos algoritmos selecionados, uma vez que utilizam atributos categóricos. Alguns atributos apenas tiveram seus valores alterados para suas respectivas descrições, no entanto, outros tiveram os valores recategorizados de forma a melhor distribuir as classes.

O atributo **TP_ESCOLA** foi alterado onde a classe 1 virou 'Nao Respondeu', a classe 2 virou 'Publica' e a classe 3 virou 'Privada'. E o mesmo foi feito para o atributo **TP_DEPENDENCIA_ADM_ESC**, onde a classe 1 virou 'Federal', a classe 2 virou 'Estadual', a classe 3 virou 'Municipal', a classe 4 virou 'Privada' esses dois atributos não tiveram seus nomes alterados. Os atributos das perguntas socioeconômicos foram renomeados para facilitar a compreensão dos mesmos como exemplos: **Q001** virou **Q01_Educacao_Pai**, **Q002** virou **Q02_Educacao_Mae** e assim por diante e suas classes não foram alteradas.

3.5 Mineração de Dados

A mineração de dados possui diversos métodos de extração de conhecimento, tais como classificação, regressão, agrupamento e regras de associação. Este último método tem como objetivo identificar conjuntos de itens frequentes dentro de uma base de dados, permitindo descobrir padrões relevantes em grandes volumes de informação (Mariano *et al.*, 2021).

3.5.1 Regras de Associação

Uma regra de associação é composta por dois conjuntos não vazios de itens, A e B, e é representada na forma $A \Rightarrow B$, onde A é denominado *Antecedente* e B é denominado *Consequente* da regra (Mariano *et al.*, 2021). Um item pertencente a um dos conjuntos não pode aparecer simultaneamente no outro.

As duas métricas fundamentais utilizadas para avaliar regras de associação são o *suporte* e a *confiança*. Uma regra é considerada forte quando atende a um suporte mínimo e a uma confiança mínima (Han; Kamber, 2006). O suporte de uma regra $A \Rightarrow$

B é definido como a proporção de transações da base que contêm simultaneamente os itens de A e B, conforme a Equação 3.1.

$$\text{Suporte } (A \Rightarrow B) = P(A \cup B) = \frac{\text{Frequência de transações contendo } A \text{ e } B}{\text{Total de transações}} \tag{3.1}$$

A confiança representa a probabilidade de uma transação conter B, dado que ela contém A, e é apresentada na Equação 3.2:

$$\text{Confiança } (A \Rightarrow B) = P(B \mid A) = \frac{\text{Suporte}(A \cup B)}{\text{Suporte}(A)} \tag{3.2}$$

Outra métrica amplamente utilizada é o *lift*, que indica o grau de correlação entre os conjuntos A e B. Se A e B forem independentes, então $P(A \cup B) = P(A)P(B)$; caso contrário, há dependência e correlação entre eles (Han; Kamber, 2006). O cálculo do lift é apresentado na Equação 3.3.

$$\text{Lift}(A \Rightarrow B) = \frac{P(A \cup B)}{P(A)P(B)} = \frac{\text{Confiança}(A \Rightarrow B)}{\text{Suporte}(B)} \tag{3.3}$$

A interpretação do lift segue três casos:

- Lift > 1: A e B são positivamente correlacionados;
- Lift < 1: A e B são negativamente correlacionados;
- Lift = 1: A e B são independentes.

3.5.2 Agrupamento

O agrupamento (*clustering*) é uma das técnicas fundamentais da mineração de dados, cujo objetivo é particionar um conjunto de objetos em grupos (*clusters*) de forma que elementos dentro de um mesmo grupo sejam mais semelhantes entre si do que em relação a elementos de outros grupos (Macqueen, 1967). Ao contrário dos métodos supervisionados, o processo de agrupamento é um método não supervisionado, uma vez que não depende de rótulos prévios ou variáveis-alvo.

Entre os algoritmos de agrupamento mais utilizados destaca-se o *k-means*, que busca minimizar a soma das distâncias entre cada instância e o centróide de seu cluster. A função objetivo do *k-means* é apresentada na Equação 3.4.

$$J = \sum_{i=1}^{k} \sum_{x_j \in C_i} \|x_j - \mu_i\|^2 \tag{3.4}$$

onde k é o número de grupos, C_i é o conjunto de elementos pertencentes ao cluster i, μ_i é o centróide do cluster e $\|\cdot\|$ denota a distância euclidiana. A técnica é especialmente útil para identificar padrões naturais nos dados e perfis de participantes, como no caso do Enem, possibilitando observar agrupamentos por desempenho, renda familiar, ou condições socioeconômicas.

3.5.3 Classificação

A classificação é um método supervisionado que consiste em aprender uma função que mapeie instâncias de entrada em classes predefinidas, a partir de exemplos rotulados. O objetivo é que o modelo aprendido generalize o padrão observado e seja capaz de predizer a classe de novas instâncias (Quinlan, 1986).

Formalmente, dado um conjunto de treinamento $D = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$, onde x_i representa um vetor de atributos e y_i a classe associada, o problema consiste em encontrar uma função f tal que:

$$f(x_i) \approx y_i \tag{3.5}$$

Entre os algoritmos de classificação mais utilizados destacam-se: árvores de decisão, máquinas de vetores de suporte (SVM), redes neurais e regressão logística. Em bases educacionais como o Enem, a classificação pode ser empregada, por exemplo, para prever faixas de desempenho, identificar perfis de risco para evasão escolar ou estimar probabilidades de acerto em componentes específicos da prova.

3.5.4 Regressão logística

A regressão logística é um método supervisionado amplamente utilizado para problemas de classificação binária. Seu objetivo é modelar a probabilidade de ocorrência de um evento em função de uma combinação linear dos atributos de entrada (Hosmer; Lemeshow, 2000). A função logística (*sigmoid*) é utilizada para mapear valores reais para o intervalo $(0, 1)$, permitindo que sejam interpretados como probabilidades.

A Equação 3.6 apresenta o modelo da regressão logística para um vetor de características x:

$$P(Y = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n)}} \tag{3.6}$$

onde $\beta_0, \beta_1, \ldots, \beta_n$ são os coeficientes estimados a partir dos dados. O modelo é ajustado pelo método da máxima verossimilhança, buscando os parâmetros que maximizam a probabilidade dos dados observados.

A regressão logística é particularmente útil para prever eventos binários relacionados ao desempenho educacional, como a probabilidade de um candidato atingir determinada faixa de nota, completar a prova ou obter desempenho acima da média geral. Sua interpretabilidade e eficiência tornam-na uma técnica amplamente utilizada em análises estatísticas e em mineração de dados.

3.5.5 Algoritmos

Com a base de dados do Enem 2023 devidamente tratada e organizada, diferentes técnicas de mineração de dados e aprendizado de máquina foram aplicadas com o objetivo de identificar padrões, extrair conhecimento e compreender de maneira mais profunda os fatores associados ao desempenho dos participantes. A diversidade metodológica empregada visa contemplar tanto abordagens preditivas quanto exploratórias, permitindo uma análise mais ampla do comportamento dos dados.

Inicialmente, foi utilizada a mineração de regras de associação, com destaque para o algoritmo *FP-Growth*. Este método foi escolhido por sua alta eficiência computacional e por sua capacidade de encontrar padrões frequentes sem a necessidade de geração explícita de todos os possíveis conjuntos de itens, como ocorre no tradicional algoritmo *Apriori*. Conforme aponta a literatura, o *FP-Growth* apresenta desempenho substancialmente superior ao *Apriori*, especialmente em bases de grande porte ou quando são adotados valores de suporte reduzidos, tornando-o adequado para o volume de dados do Enem 2023.

Além das regras de associação, foram empregados diferentes modelos de aprendizado de máquina supervisionado, com o objetivo de estimar variáveis relacionadas ao desempenho dos participantes. Entre os modelos utilizados, destacam-se: o *Decision Tree Regressor*, que estrutura o processo de predição em forma de árvore de decisão; o *Random Forest*, que combina múltiplas árvores para produzir estimativas mais robustas; e a *Regressão Linear*, modelo clássico amplamente utilizado como referência por sua interpretabilidade e simplicidade.

Complementando a análise, foi também aplicada uma técnica de aprendizado de máquina não supervisionado: o algoritmo *k-means*. Tal método foi utilizado para identificar agrupamentos internos na base, permitindo detectar perfis de participantes com características semelhantes em termos de desempenho e condições socioeconômicas. Essa abordagem auxilia na compreensão da estrutura dos dados e na formação de grupos representativos.
A integração dessas técnicas possibilita uma análise ampla e consistente, combinando descoberta de padrões, modelagem preditiva e identificação de grupos naturais, oferecendo assim uma visão robusta sobre os fatores que influenciam o desempenho no Enem 2023.

3.5.5.1 Apriori e FP-Growth

No campo das regras de associação, o algoritmo Apriori é um dos métodos mais tradicionais e amplamente utilizados. Entretanto, apesar de sua relevância histórica, o Apriori apresenta limitações significativas de desempenho, especialmente quando aplicado a bases de dados grandes ou quando é necessário utilizar valores baixos de suporte mínimo (Agrawal; Srikant, 1994).

O Apriori baseia-se em uma abordagem iterativa de geração e teste de candidatos, realizando múltiplas varreduras completas na base de dados. Dessa forma, seu tempo de execução aumenta substancialmente conforme o número de itens cresce.

Em contraste, o algoritmo FP-Growth (*Frequent Pattern Growth*) elimina a necessidade de gerar candidatos explicitamente, utilizando uma estrutura compacta denominada *FP-tree*. Essa estratégia reduz drasticamente o número de leituras na base, além de diminuir a complexidade computacional.

Segundo Agrawal e Srikant (1994), quanto maior o conjunto de dados ou quanto menor o valor definido para o suporte mínimo, maior será o tempo de execução dos algoritmos. Contudo, na maioria dos cenários avaliados, o FP-Growth apresenta tempo de processamento muito inferior ao Apriori, tornando-se mais adequado para aplicações em larga escala.

3.5.5.2 Decision Tree Regressor

O modelo *DecisionTreeRegressor* constrói uma estrutura hierárquica em forma de árvore, na qual decisões sucessivas particionam o espaço de atributos em regiões homogêneas em relação à variável alvo. As árvores de decisão são modelos facilmente interpretáveis, permitindo visualizar diretamente os critérios de divisão utilizados na predição (Quinlan, 1986). No contexto deste estudo, foram empregadas para estimar valores contínuos relacionados ao desempenho dos participantes.

3.5.5.3 Random Forest

O *Random Forest* é um método de comitê baseado na construção de múltiplas árvores de decisão, combinando seus resultados para aumentar a robustez e reduzir a variância das predições. O modelo opera por meio da técnica de *bagging*, realizando amostragem bootstrap e selecionando subconjuntos aleatórios de atributos para cada divisão da árvore (Breiman, 2001). Sua capacidade de lidar com grandes bases de dados e capturar relações não lineares motivou sua aplicação neste estudo.

3.5.5.4 Regressão Linear

A regressão linear foi utilizada como modelo base para estimar relações lineares entre os atributos socioeconômicos e as notas dos participantes. O modelo busca ajustar uma função linear da forma:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n, \tag{3.7}$$

onde $\hat{y}$ representa o valor previsto e $\beta_0, \beta_1, \ldots, \beta_n$ são os coeficientes estimados pelo método dos mínimos quadrados (Draper; Smith, 1998). Apesar de simples, o modelo é eficiente e interpretável, servindo como linha de referência nas análises.

3.5.5.5 K-Means

O método *k-means* foi utilizado como abordagem não supervisionada para identificação de grupos naturais entre os participantes. O algoritmo busca particionar os dados em k clusters, minimizando a soma das distâncias quadráticas entre cada instância e o centróide do grupo (Macqueen, 1967), conforme a função objetivo:

$$J = \sum_{i=1}^{k} \sum_{x_j \in C_i} \|x_j - \mu_i\|^2. \tag{3.8}$$

Sua aplicação permite identificar perfis semelhantes de estudantes em termos de desempenho e características socioeconômicas, contribuindo para análises agrupadas.

3.5.6 Pós-Processamento

Após a aplicação das diferentes técnicas de mineração de dados — incluindo regras de associação por meio do algoritmo *FP-Growth*, modelos supervisionados como *DecisionTreeRegressor*, *Random Forest* e Regressão Linear, além do método não supervisionado *k-means* — os resultados obtidos foram integrados a ferramentas de visualização analítica, de modo a permitir uma interpretação mais clara e aprofundada dos padrões identificados.

Esse processo de pós-processamento possibilita uma análise mais dinâmica e intuitiva, facilitando a validação dos achados, a comparação entre métodos e a identificação de relações relevantes entre variáveis socioeconômicas e de desempenho. Dessa forma, a interpretação visual dos resultados contribui para transformar os padrões detectados pelos algoritmos em informações úteis e aplicáveis para estudos educacionais e tomada de decisão.

4 RESULTADOS

Foram empregados quatro algoritmos de mineração de dados, cada um representando uma categoria distinta de técnicas. O algoritmo K-Means foi utilizado como exemplo de método de agrupamento, permitindo a identificação de perfis semelhantes entre os estudantes. No campo dos algoritmos preditivos, foram aplicados a Regressão Linear, a Random Forest e a Árvore de Decisão, possibilitando analisar a influência de diferentes variáveis explicativas sobre a variável criada, denominada *Média Geral*. Além desses, foi ainda empregado o algoritmo FP-Growth, representativo da categoria de regras de associação, com o objetivo de identificar padrões frequentes entre as variáveis socioeconômicas e educacionais, buscando compreender como determinadas combinações de fatores se relacionam com o desempenho médio dos estudantes.

No que se refere ao algoritmo de agrupamento K-Means, os resultados demonstraram a formação de três *clusters* distintos em ambas as bases (Figura 3). As distribuições apresentaram separações relativamente consistentes, ainda que não perfeitamente lineares. A análise dos perfis identificados revelou padrões distintos de acordo com variáveis socioeconômicas e educacionais, permitindo observar a presença de grupos com médias mais elevadas, em geral associados a melhores condições de infraestrutura domiciliar e maior escolaridade dos responsáveis, em contraste com perfis em que tais indicadores são menos expressivos. Essa diferenciação sugere a relevância de variáveis de contexto familiar e socioeconômico na composição da *Média Geral*.

Figura 3 – Análise comparativa — K-Means *Clustering*

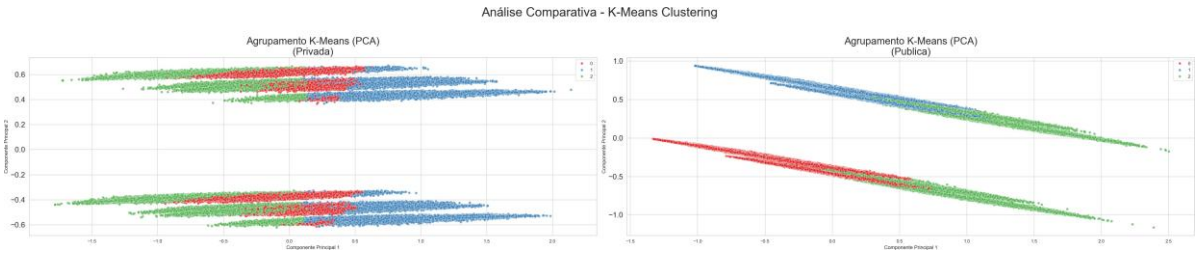

Fonte: Próprio autor.

A análise dos perfis de *clusters* detalhados para as duas bases (Quadro 2) reforçou a existência de grupos com características socioeconômicas específicas. Entre os fatores mais recorrentes, destacaram-se a escolaridade dos pais, a renda familiar e a infraestrutura do domicílio, com variações que refletem diferenças significativas entre instituições privadas e públicas.

Quadro 2 - Valores dos Clusters

Escola	Privada			Publica		
Cluster	0	1	2	0	1	2
TP_FAIXA_ETARIA	2	2	2	3	3	3
TP_SEXO	F	F	F	F	M	F
Q01_Educacao_Pai	E	G	E	E	E	E
Q02_Educacao_Mae	E	G	E	E	E	E
Q03_Grupo_Ocupacao_Pai	D	E	D	C	C	C
Q04_Grupo_Ocupacao_Mae	D	D	D	B	B	B
Q05_Moradores/Residencia	4	4	4	4	4	4
Q06_Renda_Familiar_Mensal	G	Q	G	B	B	C
Q07_Empregado_Domestico	A	A	A	A	A	A
Q08_Banheiro/Residencia	C	E	B	B	B	B
Q09_Quartos/Residencia	D	D	C	C	C	D
Q10_Carro/Residencia	B	C	B	A	A	B
Q11_Moto/Residencia	A	A	A	A	A	A
Q12_Geladeira/Residencia	B	B	B	B	B	B
Q13_Freezer/Residencia	B	B	B	A	A	B
Q14_Maq_Lavar_Roupa/Residencia	B	B	B	A	B	B
Q15_Maq_Secar_Roupa/Residencia	A	A	A	A	A	A
Q16_Micro-ondas/Residencia	B	B	B	A	A	B
Q17_Maq_Lavar_Louca/Residencia	A	A	A	A	A	A
Q18_Aspirador/Residencia	B	B	A	A	A	B
Q19_TV/Residencia	C	E	B	B	B	B
Q20_DVD/Residencia	A	B	A	A	A	A
Q21_TV_Assinatura/Residencia	A	B	A	A	A	A
Q22_Celular/Residencia	D	E	D	C	D	E

Escola	Privada			Publica		
Cluster	0	1	2	0	1	2
Q23_Telefone_Fixo/Residencia	A	A	A	A	A	A
Q24_PC/Residencia	B	C	B	A	A	B
Q25_Acesso_Internet	B	B	B	B	B	B
NU_MEDIA_GERAL	614,63	639,93	597,54	508,7	507,5	546,48

Fonte: Próprio autor.

Observa-se que a variável TP_FAIXA_ETARIA (2 – idade 17 anos, 3 – idade 18 anos); Q01_Educacao_Pai e Q02_Educacao_Mae (E – Completou o Ensino Médio, mas não completou a Faculdade; G – Completou a Pós-graduação); Q03_Grupo_Ocupacao_Pai e Q04_Grupo_Ocupacao_Mae (B – Diarista, empregado doméstico, cuidador de idosos, babá, cozinheiro (em casas particulares), motorista particular, jardineiro, faxineiro de empresas e prédios, vigilante, porteiro, carteiro, *office-boy*, vendedor, caixa, atendente de loja, auxiliar administrativo, recepcionista, servente de pedreiro, repositor de mercadoria; C – Padeiro, cozinheiro industrial ou em restaurantes, sapateiro, costureiro, joalheiro, torneiro mecânico, operador de máquinas, soldador, operário de fábrica, trabalhador da mineração, pedreiro, pintor, eletricista, encanador, motorista, caminhoneiro, taxista; D – Professor (de ensino fundamental ou médio, idioma, música, artes etc.), técnico (de enfermagem, contabilidade, eletrônica etc.), policial, militar de baixa patente (soldado, cabo, sargento), corretor de imóveis, supervisor, gerente, mestre de obras, pastor, microempresário (proprietário de empresa com menos de 10 empregados), pequeno comerciante, pequeno proprietário de terras, trabalhador autônomo ou por conta própria; E – Médico, engenheiro, dentista, psicólogo, economista, advogado, juiz, promotor, defensor, delegado, tenente, capitão, coronel, professor universitário, diretor em empresas públicas ou privadas, político, proprietário de empresas com mais de 10 empregados); Q05_Moradores/Residencia (4 – moram 4 pessoas); Q06_Renda_Familiar_Mensal (B – Até R$ 1.320,00; C – De R$ 1.320,01 até R$ 1.980,00; G – De R$ 3.960,01até R$ 5.280,00; Q – Acima de R$ 26.400,00); Q07_Empregado_Domestico (A – Não); Q08_Banheiro/Residencia, Q09_Quartos/Residencia, Q10_Carro/Residencia, Q11_Moto/Residencia, Q12_Geladeira/Residencia, Q13_Freezer/Residencia, Q14_Maq_Lavar_Ro Q15_Maq_Secar_Roupa/Residencia,Q16_Micro-ondas/Residencia, Q17_Maq_Lavar_Louca/ Residencia, Q19_TV/Residencia, Q22_Celular/Residencia e Q24_PC/Residencia (A – Não; B – Sim, uma; C – Sim, duas; D – Sim, três; E – Sim, quatro ou mais); Q18_Aspirador/Residencia, Q20_DVD/Residencia,

Q21_TV_Assinatura/Residencia, Q23_Telefone_Fixo/Residencia e Q25_Acesso_Internet (A – Não; B – Sim).

Em relação aos modelos preditivos, a Regressão Linear apresentou baixo poder explicativo, como evidenciado pela dispersão dos pontos em torno da reta de tendência (Figura 4). Apesar da limitação, a análise dos coeficientes destacados nos gráficos permitiu identificar diferenças relevantes entre as duas bases de dados. Na base pública, a variável referente à escolaridade da mãe apresentou maior impacto sobre a *Média Geral*, enquanto a escolaridade do pai não figurou entre os dez primeiros fatores mais relevantes. Esse resultado sugere que, nesse contexto, o capital educacional materno exerce papel mais determinante sobre o desempenho dos estudantes. Por outro lado, na base privada, observou-se comportamento distinto: a escolaridade do pai destacou-se como fator de maior peso, seguida pela escolaridade da mãe. Essa inversão na hierarquia de relevância pode indicar diferenças no papel atribuído a cada responsável no acompanhamento escolar e no suporte educacional oferecido em ambientes socioeconômicos distintos.

O Random Forest apresentou desempenho superior em termos de ajuste, com maior capacidade preditiva em comparação à Regressão Linear. Conforme apresentado na Figura 5, a renda familiar mensal e a escolaridade dos responsáveis emergiram como os fatores de maior contribuição para a variação da *Média Geral*, tanto na base privada quanto na pública. Além disso, variáveis relacionadas à posse de bens duráveis e à infraestrutura residencial apresentaram importância complementar, sugerindo que o contexto socioeconômico exerce influência significativa na variável-alvo.

A Árvore de Decisão, embora menos robusta que o Random Forest, confirmou a tendência de predominância da escolaridade dos responsáveis e da renda familiar

Figura 4 – Análise comparativa — Regressão Linear

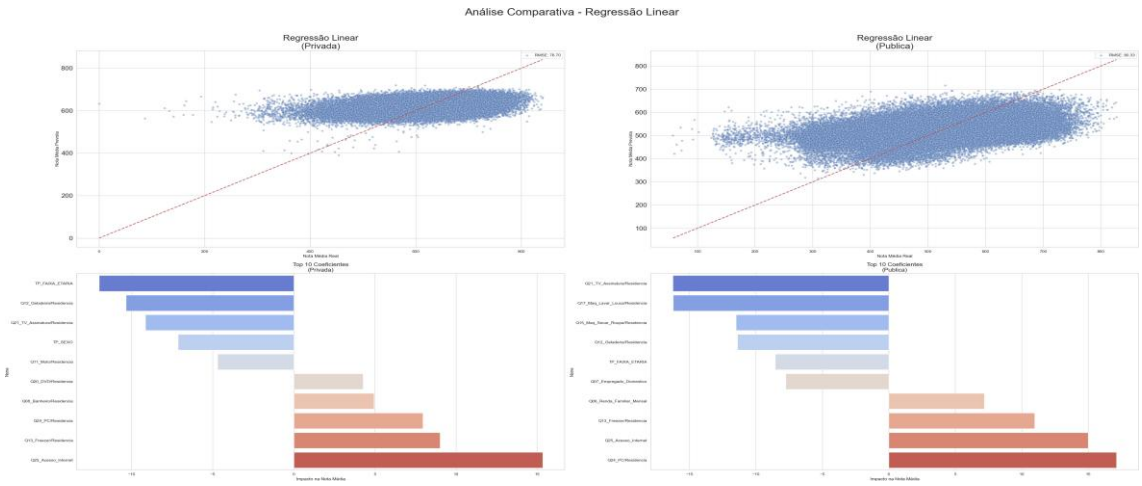

Fonte: Próprio autor.

como fatores centrais para a explicação da *Média Geral*. No entanto, observou-se maior propensão ao sobreajuste e menor poder de generalização, o que é inerente a essa técnica quando comparada a métodos *ensemble*, como ilustrado na Figura 6, que apresenta a análise comparativa.

Figura 5 – Análise comparativa — Random Forest (com variáveis consolidadas)

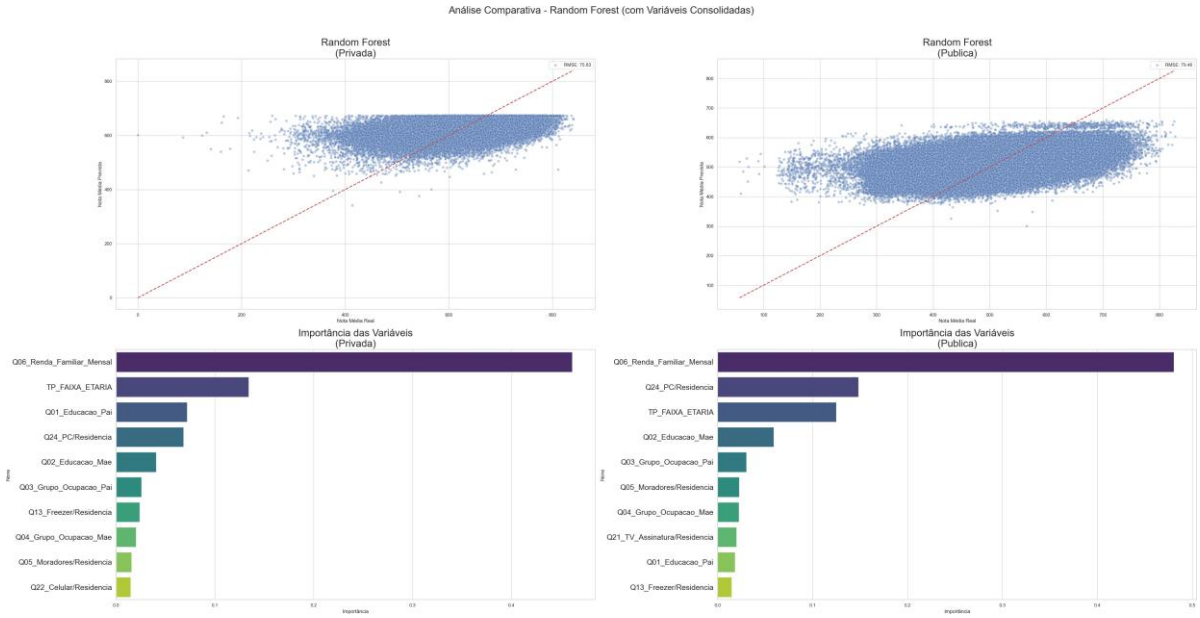

Fonte: Próprio autor.

Para aprofundar a análise descritiva, o algoritmo FP-Growth foi aplicado para minerar regras de associação. Os resultados, apresentados nas Quadro 3 e 4, revelam dinâmicas socioeconômicas marcadamente distintas.

Figura 6 – Análise comparativa — Árvore de Decisão

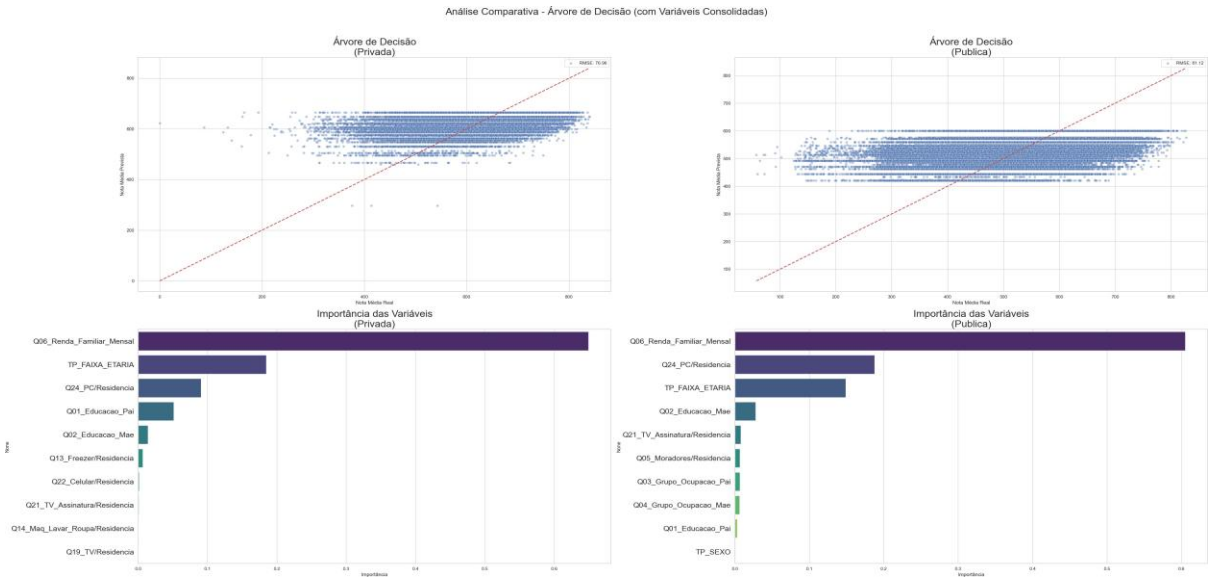

Fonte: Próprio autor.

Na base de escolas públicas, as regras apontam para um perfil de escassez, em que a ausência de um bem básico é um forte indicador da ausência de outros. Em contraste, na base de escolas privadas, as regras definem um perfil de abundância, no qual a presença de indicadores de alto capital socioeconômico garante a posse de outros recursos. Essa análise complementa a segmentação do K-Means e reforça a conclusão central deste estudo: as realidades socioeconômicas dos dois grupos são profundamente diferentes.

De modo geral, a análise comparativa evidenciou consistência na identificação dos principais determinantes da variável *Média Geral*, destacando-se a centralidade da renda familiar e da escolaridade dos pais. Contudo, verificou-se que a influência da escolaridade de cada responsável varia conforme o tipo de instituição: nas escolas públicas, a escolaridade materna se mostra mais determinante, enquanto nas privadas o protagonismo recai sobre a escolaridade paterna. Tal constatação reforça a hipótese de que o desempenho escolar não pode ser compreendido de forma isolada, estando diretamente condicionado às condições socioeconômicas e culturais dos estudantes, influenciado pelo capital educacional e pelos recursos disponíveis no ambiente família.

Quadro 3 - Top 5 regras gerais para Base de Escolas Públicas

Regra	Antecedente	Consequente	Suporte	Confiança
1	Q16_Micro-ondas/Residencia=A, Q14_Maq_Lavar_Roupa/Residencia=A, TP_SEXO=F	Q17_Maq_Lavar_Louca/ Residencia=A	0.2109	0.9978
2	TP_SEXO=F, Q13_Freezer/Residencia=A, Q14_Maq_Lavar_Roupa/Residencia=A	Q17_Maq_Lavar_Louca/ Residencia=A	0.2020	0.9977
3	Q16_Micro-ondas/Residencia=A, Q13_Freezer/Residencia=A, Q14_Maq_Lavar_Roupa/Residencia=A	Q17_Maq_Lavar_Louca/ Residencia=A	0.2660	0.9977
4	Q11_Moto/Residencia=A, Q16_Micro-ondas/Residencia=A, Q14_Maq_Lavar_Roupa/Residencia=A	Q17_Maq_Lavar_Louca/ Residencia=A	0.2408	0.9977
5	TP_SEXO=F, Q14_Maq_Lavar_Roupa/Residencia=A, Q21_TV_Assinatura/Residencia=A	Q17_Maq_Lavar_Louca/ Residencia=A	0.2383	0.9976

Fonte: proprio autor

Quadro 4 - Top 5 regras gerais para Base de Escolas Privadas

Regra	Antecedente	Consequente	Suporte	Confiança
1	Q03_Grupo_Ocupacao_Pai=E, Q18_Aspirador/Residencia=B, Q21_TV_Assinatura/Residencia=B	Q25_Acesso_Internet=B	0.1577	0.9995
2	Q22_Celular/Residencia=E, Q18_Aspirador/Residencia=B, Q21_TV_Assinatura/Residencia=B	Q25_Acesso_Internet=B	0.1952	0.9995
3	Q18_Aspirador/Residencia=B, Q02_Educacao_Mae=G, Q21_TV_Assinatura/Residencia=B	Q25_Acesso_Internet=B	0.1504	0.9995
4	Q18_Aspirador/Residencia=B, Q04_Grupo_Ocupacao_Mae=E	Q25_Acesso_Internet=B	0.1598	0.9995
5	Q15_Maq_Secar_Roupa/Residencia=B, Q14_Maq_Lavar_Roupa/Residencia=B, Q21_TV_Assinatura/Residencia=B	Q25_Acesso_Internet=B	0.1604	0.9995

Fonte: Próprio autor

5 CONCLUSÃO

5.1 Considerações Finais

A análise conjunta dos modelos preditivos e de agrupamento convergiu para um achado central: o fator socioeconômico, representado de forma mais proeminente pela renda familiar mensal, mostrou-se o principal determinante do desempenho dos participantes. O modelo *Random Forest*, que apresentou o melhor desempenho preditivo, ranqueou a renda como a variável de maior importância em todos os cenários analisados.

Além disso, foi identificada uma nuance relevante relacionada à escolaridade parental. Nos modelos direcionados a estudantes de escolas públicas, a escolaridade da mãe apresentou maior impacto sobre o desempenho. Em contrapartida, no contexto das escolas privadas, a escolaridade do pai teve maior peso, sugerindo dinâmicas distintas de capital cultural entre os grupos.

No que diz respeito às técnicas de regras de associação, a aplicação do algoritmo *FP-Growth* permitiu identificar padrões de coocorrência, embora tenha demonstrado limitações frente ao tipo de investigação proposta neste estudo. Sua principal desvantagem reside na natureza exploratória do método, que retorna todas as regras que atendem aos critérios de suporte e confiança, sem permitir uma busca

direcionada para resultados específicos, como alta ou baixa média geral. Assim, os padrões identificados revelam perfis de abundância e escassez de recursos, reforçando conclusões obtidas pelos demais modelos, mas contribuindo pouco para a explicação direta da variável-alvo.

Em termos computacionais, o *FP-Growth* também apresentou limitações. Sua performance está diretamente relacionada ao tamanho e à complexidade da base de dados. Quanto maior o número de registros e variáveis, maior o tempo necessário para gerar e validar todas as combinações frequentes, tornando o método menos prático para análises rápidas em bases de grande escala, como o conjunto de dados do Enem 2023.

No conjunto dos achados, este estudo demonstrou a extração bem-sucedida de conhecimento relevante a partir de dados abertos, reforçando a forte correlação entre fatores socioeconômicos e desempenho educacional. Observou-se que modelos como o *Random Forest* são mais adequados para avaliar importância de variáveis em dados complexos, enquanto o *FP-Growth*, embora útil na descoberta de padrões gerais, mostra-se menos eficiente para responder a questões de pesquisa direcionadas.

Como perspectiva para trabalhos futuros, sugere-se a incorporação de outras variáveis, especialmente relacionadas ao contexto escolar, bem como a aplicação de técnicas de modelagem causal, de modo a aprofundar a compreensão das relações identificadas ao longo deste estudo.

5.2 Trabalhos Futuros

Este estudo abriu diversas possibilidades para investigações futuras. Primeiramente, sugere-se a inclusão de variáveis adicionais que possam enriquecer a análise, como características específicas das escolas, tais como infraestrutura, proporção aluno-professor, e programas pedagógicos adotados. Essas informações poderiam fornecer uma visão mais abrangente sobre os fatores que influenciam o desempenho dos estudantes.

Além disso, a aplicação de técnicas de modelagem causal poderia ser explorada para investigar as relações de causa e efeito entre as variáveis socioeconômicas e o desempenho educacional. Métodos como Modelos de Equações Estruturais (SEM) ou Análise de Caminho poderiam ajudar a esclarecer como diferentes fatores interagem e contribuem para os resultados dos estudantes.

REFERÊNCIAS

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules in large databases. Morgan Kaufmann Publishers, San Francisco, p. 487–499, 1994. Acesso em: 9 fev. 2025. Disponível em: <https://dl.acm.org/doi/10.5555/645920.672836>.

BAEK, C.; DOLECK, T. Educational data mining: A bibliometric analysis of an emerging field. *IEEE Access*, v. 10, p. 31289–31296, 2022. Acesso em: 20 mar. 2025.

BAKER, R. Data mining for education. *International Encyclopedia of Education*, v. 7, p. 112–118, 2010. Acesso em: 14 fev. 2025. Disponível em: <https: //www.researchgate.net/publication/285852296_Data_mining_for_education>.

BEHRMAN, K. R. *Fundamentos de Python para Ciência de Dados*. Porto Alegre: Grupo A, 2023.

BLEI, D. M.; NG, A. Y.; JORDAN, M. I. Latent dirichlet allocation. *Journal of Machine Learning Research*, v. 3, p. 993–1022, 2003. Acesso em: 23 dez. 2024. Disponível em: <http://jmlr.org/papers/v3/blei03a.html>.

BOX, G. E. P. *et al. Time Series Analysis*. 5. ed. Nova York: John Wiley & Sons, 2016.

Brasil. Ministério da Gestão e da Inovação em Serviços Públicos. *Dados Abertos*. Brasília: Governo Digital, 2022. Acesso em: 30 maio 2023. Disponível em: <https://www.gov.br/governodigital/pt-br/dados-abertos>.

BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Acesso em: 23 nov. 2024.

BREUNIG, M. M. *et al.* Lof: Identifying density-based local outliers. *SIGMOD Record*, v. 29, n. 2, p. 93–104, 2000. Acesso em: 20 dez. 2024.

CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, v. 20, n. 3, p. 273–297, 1995. Acesso em: 30 jan. 2025.

COVER, T.; HART, P. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, v. 13, n. 1, p. 21–27, 1967. Acesso em: 13 dez. 2024.

DHAENENS, C.; JOURDAN, L. Metaheuristics for data mining: Survey and opportunities for big data. *4OR: A Quarterly Journal of Operations Research*, v. 17, p. 115–139, 2019. Acesso em: 14 fev. 2025.

DRAPER, N. R.; SMITH, H. *Applied Regression Analysis*. 3. ed. Nova York: John Wiley & Sons, 1998. (Wiley Series in Probability and Statistics). Acesso em: 14 fev. 2025. ISBN 9780471170822. Disponível em: <https: //doi.org/10.1002/9781118625590>.

ESTER, M. *et al.* A density-based algorithm for discovering clusters in large spatial databases with noise. In: *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*. Portland: AAAI Press, 1996. p. 226–231.

FAYYAD, U.; PIATETSKY-SHAPIRO, G.; SMYTH, P. From data mining to knowledge discovery in databases. *AI Magazine*, v. 17, n. 3, p. 37–54, 1996. Acesso em: 10 maio 2023. Disponível em: <https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1230/1131>.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016. Acesso em: 26 jan. 2025. Disponível em: <http://www.deeplearningbook.org>.

HAN, J.; KAMBER, M. *Data Mining: Concepts and Techniques*. 2. ed. San Francisco: Elsevier, 2006.

HAN, J.; PEI, J.; YIN, Y. Mining frequent patterns without candidate generation. *SIGMOD Record*, v. 29, n. 2, p. 1–12, 2000. Acesso em: 25 jan. 2025.

HARRIS, C. R. *et al.* Array programming with numpy. *Nature*, v. 585, n. 7825, p. 357–362, 2020. Acesso em: 2 fev. 2025.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. Acesso em: 21 dez. 2024.

HOSMER, D. W.; LEMESHOW, S. *Applied Logistic Regression*. 2. ed. Nova York: John Wiley & Sons, 2000.

HUNTER, J. D. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90–95, 2007. Acesso em: 3 mar. 2025.

(INEP), B. I. N. de Estudos e P. E. A. T. *Áreas de Atuação – Avaliações e Exames Educacionais – ENEM*. 2025. Acesso em: 16 nov. 2025. Disponível em: <https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/enem>.

JOLLIFFE, I. T. *Principal Component Analysis*. 2. ed. Nova York: Springer, 2002.

MACQUEEN, J. Some methods for classification and analysis of multivariate observations. In: *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*. Berkeley: University of California Press, 1967. p. 281–297.

MARIANO, D. C. B.; MARQUES, L. T.; SILVA, M. S. *et al. Data Mining*. Porto Alegre, RS: Grupo A, 2021. Acesso em: 25 nov. 2025. ISBN 9786556900292. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9786556900292/>.

PALACIOS, C. A. *et al.* Knowledge discovery for higher education student retention based on data mining: Machine learning algorithms and case study in chile. *Entropy*, v. 23, n. 4, 2021. Acesso em: 20 abr. 2021.

PEDREGOSA, F. *et al.* Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Acesso em: 8 fev. 2025. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>.

Python Software Foundation. *Python*. 2024. Acesso em: 2 fev. 2025. Disponível em: <https://www.python.org/about/>.

QUINLAN, J. R. Induction of decision trees. *Machine Learning*, v. 1, n. 1, p. 81–106, 1986. Acesso em: 10 fev. 2025.

ROMERO, C.; VENTURA, S. Educational data mining: A survey from 1995 to 2005. *Expert Systems with Applications*, v. 33, n. 1, p. 135–146, 2007. Acesso em: 14 fev. 2025.

SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988. Acesso em: 9 fev. 2025.

SERGIO, M. C.; SILVA, T. D. N.; GONçALVES, A. L. Descoberta de conhecimento a partir de informações não estruturadas por meio de técnicas de correlação e associação. *Em Questão*, v. 22, n. 2, p. 87–113, 2016. Acesso em: 8 mar. 2025.

TAYLOR, S. J.; LETHAM, B. Forecasting at scale. *The American Statistician*, v. 72, n. 1, p. 37–45, 2018. Acesso em: 1 fev. 2025.

The Pandas Development Team. *Pandas: Powerful Python Data Analysis Toolkit*. 2020. Acesso em: 8 fev. 2025. Disponível em: <https://pandas.pydata.org>.

VIRTANEN, P.; OLIPHANT, T. E.; GOMMERS, R. Scipy 1.0: Fundamental algorithms for scientific computing in python. *Nature Methods*, v. 17, p. 261–272, 2020. Acesso em: 8 fev. 2025.

WASKOM, M. L. Seaborn: Statistical data visualization. *Journal of Open Source Software*, v. 6, n. 60, p. 3021, 2021. Acesso em: 12 fev. 2025.

ZORIć, A. B. *Benefits of Educational Data Mining*. 2020. 12-16 p. Acesso em: 20 mar. 2025. Disponível em: <https://doi.org/10.18775/jibrm.1849-8558.2015.61.3002>.

ANEXO A – DICIONÁRIO DE DADOS

Dados do participante

- **NU_INSCRICAO**: Número de inscrição do participante.
- **NU_ANO**: Ano de aplicação do ENEM.
- **TP_FAIXA_ETARIA**: Faixa etária do participante.
  - 1 – Menor de 17 anos
  - 2 – 17 anos
  - 3 – 18 anos
  - 4 – 19 anos
  - 5 – 20 anos
  - 6 – 21 anos
  - 7 – 22 anos
  - 8 – 23 anos
  - 9 – 24 anos
  - 10 – 25 anos
  - 11 – Entre 26 e 30 anos
  - 12 – Entre 31 e 35 anos
  - 13 – Entre 36 e 40 anos
  - 14 – Entre 41 e 45 anos
  - 15 – Entre 46 e 50 anos
  - 16 – Entre 51 e 55 anos
  - 17 – Entre 56 e 60 anos
  - 18 – Entre 61 e 65 anos
  - 19 – Entre 66 e 70 anos
  - 20 – Maior de 70 anos
- **TP_SEXO**: Sexo.
  - M – Masculino
  - F – Feminino

- **TP_ESTADO_CIVIL**: Estado civil.
  - 0 – Não informado
  - 1 – Solteiro(a)
  - 2 – Casado(a) / Mora com companheiro(a)
  - 3 – Divorciado(a) / Desquitado(a) / Separado(a)
  - 4 – Viúvo(a)
- **TP_COR_RACA**: Cor/raça.
  - 0 – Não declarado
  - 1 – Branca
  - 2 – Preta
  - 3 – Parda
  - 4 – Amarela
  - 5 – Indígena
  - 6 – Não dispõe da informação
- **TP_NACIONALIDADE**: Nacionalidade.
  - 0 – Não informado
  - 1 – Brasileiro(a)
  - 2 – Brasileiro(a) naturalizado(a)
  - 3 – Estrangeiro(a)
  - 4 – Brasileiro(a) nato(a), nascido(a) no exterior
- **TP_ST_CONCLUSAO**: Situação de conclusão do Ensino Médio.
  - 1 – Já concluiu o Ensino Médio
  - 2 – Está cursando e concluirá o Ensino Médio em 2023
  - 3 – Está cursando e concluirá o Ensino Médio após 2023
  - 4 – Não concluiu e não está cursando o Ensino Médio
- **TP_ANO_CONCLUIU**: Ano de conclusão do Ensino Médio.
  - 0 – Não informado
  - 1 – 2022
  - 2 – 2021
  - 3 – 2020

  - 4 – 2019
  - 5 – 2018
  - 6 – 2017
  - 7 – 2016
  - 8 – 2015
  - 9 – 2014
  - 10 – 2013
  - 11 – 2012
  - 12 – 2011
  - 13 – 2010
  - 14 – 2009
  - 15 – 2008
  - 16 – 2007
  - 17 – Antes de 2007
- **TP_ESCOLA**: Tipo de escola do Ensino Médio.
  - 1 – Não respondeu
  - 2 – Pública
  - 3 – Privada
- **TP_ENSINO**: Tipo de instituição em que concluiu ou concluirá o Ensino Médio.
  - 1 – Ensino regular
  - 2 – Educação especial - Modalidade substitutiva
- **IN_TREINEIRO**: Indica se o inscrito fez a prova apenas para treinar seus conhecimentos.
  - 1 – Sim
  - 0 – Não

Dados da escola

- **CO_MUNICIPIO_ESC**: Código do município da escola.
  - 1º dígito: Região
  - 1º e 2º dígitos: UF

  - 3º, 4º, 5º e 6º dígitos: Município
  - 7º dígito: Dígito verificador
- **NO_MUNICIPIO_ESC**: Nome do município da escola.
- **CO_UF_ESC**: Código da Unidade da Federação da escola.
- **SG_UF_ESC**: Sigla da Unidade da Federação da escola.
- **TP_DEPENDENCIA_ADM_ESC**: Dependência administrativa (escola).
  - 1 – Federal
  - 2 – Estadual
  - 3 – Municipal
  - 4 – Privada
- **TP_LOCALIZACAO_ESC**: Localização (escola).
  - 1 – Urbana
  - 2 – Rural
- **TP_SIT_FUNC_ESC**: Situação de funcionamento (escola).
  - 1 – Em atividade
  - 2 – Paralisada
  - 3 – Extinta
  - 4 – Escola extinta em anos anteriores

Dados do local de aplicação da prova

- **CO_MUNICIPIO_PROVA**: Código do município de aplicação da prova.
  - 1º dígito: Região
  - 1º e 2º dígitos: UF
  - 3º, 4º, 5º e 6º dígitos: Município
  - 7º dígito: Dígito verificador
- **NO_MUNICIPIO_PROVA**: Nome do município de aplicação da prova.
- **CO_UF_PROVA**: Código da Unidade da Federação da aplicação da prova.
- **SG_UF_PROVA**: Sigla da Unidade da Federação da aplicação da prova.

Dados da prova objetiva

- **TP_PRESENCA_CN**: Presença na prova objetiva de Ciências da Natureza.
  - 0 – Faltou à prova
  - 1 – Presente na prova
  - 2 – Eliminado na prova
- **TP_PRESENCA_CH**: Presença na prova objetiva de Ciências Humanas.
  - 0 – Faltou à prova
  - 1 – Presente na prova
  - 2 – Eliminado na prova
- **TP_PRESENCA_LC**: Presença na prova objetiva de Linguagens e Códigos.
  - 0 – Faltou à prova
  - 1 – Presente na prova
  - 2 – Eliminado na prova
- **TP_PRESENCA_MT**: Presença na prova objetiva de Matemática.
  - 0 – Faltou à prova
  - 1 – Presente na prova
  - 2 – Eliminado na prova
- **CO_PROVA_CN**: Código do tipo de prova de Ciências da Natureza.
  - 1221 – Azul
  - 1222 – Amarela
  - 1223 – Rosa
  - 1224 – Cinza
  - 1225 – Rosa – Ampliada
  - 1226 – Rosa – Superampliada
  - 1227 – Laranja – Braile
  - 1228– Laranja – Adaptada Ledor
  - 1229 – Verde – Videoprova – Libras
  - 1301 – Azul (Reaplicação)
  - 1302 – Amarela (Reaplicação)

  - 1303 – Cinza (Reaplicação)
  - 1304 – Rosa (Reaplicação)

- **CO_PROVA_CH**: Código do tipo de prova de Ciências Humanas.
  - 1191 – Azul
  - 1192 – Amarela
  - 1193 – Branca
  - 1194 – Rosa
  - 1195 – Rosa – Ampliada
  - 1196 – Rosa – Superampliada
  - 1197 – Laranja – Braile
  - 1198 – Laranja – Adaptada Ledor
  - 1199 – Verde – Videoprova – Libras
  - 1271 – Azul (Reaplicação)
  - 1272 – Amarela (Reaplicação)
  - 1273 – Branca (Reaplicação)
  - 1274 – Rosa (Reaplicação)

- **CO_PROVA_LC**: Código do tipo de prova de Linguagens e Códigos.
  - 1201 – Azul
  - 1202 – Amarela
  - 1203 – Rosa
  - 1204 – Branca
  - 1205 – Rosa – Ampliada
  - 1206 – Rosa – Superampliada
  - 1207 – Laranja – Braile
  - 1208 – Laranja – Adaptada Ledor
  - 1209 – Verde – Videoprova – Libras
  - 1281 – Azul (Reaplicação)
  - 1282 – Amarela (Reaplicação)
  - 1283 – Rosa (Reaplicação)
  - 1284 – Branca (Reaplicação)

- **CO_PROVA_MT**: Código do tipo de prova de Matemática.

  - 1211 – Azul
  - 1212 – Amarela
  - 1213 – Rosa
  - 1214 – Cinza
  - 1215 – Rosa – Ampliada
  - 1216 – Rosa – Superampliada
  - 1217 – Laranja – Braile
  - 1218 – Laranja – Adaptada Ledor
  - 1219 – Verde – Videoprova – Libras
  - 1291 – Azul (Reaplicação)
  - 1292 – Amarela (Reaplicação)
  - 1293 – Rosa (Reaplicação)
  - 1294 – Cinza (Reaplicação)

- **NU_NOTA_CN**: Nota da prova de Ciências da Natureza.
- **NU_NOTA_CH**: Nota da prova de Ciências Humanas.
- **NU_NOTA_LC**: Nota da prova de Linguagens e Códigos.
- **NU_NOTA_MT**: Nota da prova de Matemática.
- **TX_RESPOSTAS_CN**: Vetor com as respostas da parte objetiva de Ciências da Natureza.
  - A, B, C, D, E, * (dupla marcação), . (em branco)
- **TX_RESPOSTAS_CH**: Vetor com as respostas da parte objetiva de Ciências Humanas.
  - A, B, C, D, E, * (dupla marcação), . (em branco)
- **TX_RESPOSTAS_LC**: Vetor com as respostas da parte objetiva de Linguagens e Códigos.
  - A, B, C, D, E, * (dupla marcação), . (em branco), 9 (item não apresentado)
- **TX_RESPOSTAS_MT**: Vetor com as respostas da parte objetiva de Matemática.
  - A, B, C, D, E, * (dupla marcação), . (em branco)
- **TP_LINGUA**: Língua estrangeira escolhida.

  - 0 – Inglês
  - 1 – Espanhol

- **TX_GABARITO_CN**: Vetor com o gabarito da parte objetiva de Ciências da Natureza.
- **TX_GABARITO_CH**: Vetor com o gabarito da parte objetiva de Ciências Humanas.
- **TX_GABARITO_LC**: Vetor com o gabarito da parte objetiva de Linguagens e Códigos.
- **TX_GABARITO_MT**: Vetor com o gabarito da parte objetiva de Matemática.

Dados da redação

- **TP_STATUS_REDACAO**: Situação da redação do participante.
  - 1 – Sem problemas
  - 2 – Anulada
  - 3 – Cópia do texto motivador
  - 4 – Em branco
  - 6 – Fuga ao tema
  - 7 – Não atendimento ao tipo textual
  - 8 – Texto insuficiente
  - 9 – Parte desconectada
- **NU_NOTA_COMP1**: Nota da competência 1 – Demonstrar domínio da modalidade escrita formal da Língua Portuguesa.
- **NU_NOTA_COMP2**: Nota da competência 2 – Compreender a proposta de redação e aplicar conceitos das várias áreas de conhecimento para desenvolver o tema dentro dos limites estruturais do texto dissertativo-argumentativo em prosa.
- **NU_NOTA_COMP3**: Nota da competência 3 – Selecionar, relacionar, organizar e interpretar informações, fatos, opiniões e argumentos em defesa de um ponto de vista.
- **NU_NOTA_COMP4**: Nota da competência 4 – Demonstrar conhecimento dos mecanismos linguísticos necessários para a construção da argumentação.
- **NU_NOTA_COMP5**: Nota da competência 5 – Elaborar proposta de intervenção para o problema abordado, respeitando os direitos humanos.

- **NU_NOTA_REDACAO**: Nota total da prova de redação.

Dados do questionário socioeconômico

- **Q001**: Até que série seu pai, ou o homem responsável por você, estudou?
  - A – Nunca estudou.
  - B – Não completou a 4ª série/5º ano do Ensino Fundamental.
  - C – Completou a 4ª série/5º ano, mas não completou a 8ª série/9º ano do Ensino Fundamental.
  - D – Completou a 8ª série/9º ano do Ensino Fundamental, mas não completou o Ensino Médio.
  - E – Completou o Ensino Médio, mas não completou a Faculdade.
  - F – Completou a Faculdade, mas não completou a Pós-graduação.
  - G – Completou a Pós-graduação.
  - H – Não sei.
- **Q002**: Até que série sua mãe, ou a mulher responsável por você, estudou?
  - A – Nunca estudou.
  - B – Não completou a 4ª série/5º ano do Ensino Fundamental.
  - C – Completou a 4ª série/5º ano, mas não completou a 8ª série/9º ano do Ensino Fundamental.
  - D – Completou a 8ª série/9º ano do Ensino Fundamental, mas não completou o Ensino Médio.
  - E – Completou o Ensino Médio, mas não completou a Faculdade.
  - F – Completou a Faculdade, mas não completou a Pós-graduação.
  - G – Completou a Pós-graduação.
  - H – Não sei.
- **Q003**: Grupo ocupacional do pai ou homem responsável.
  - A – Grupo 1: Lavrador, agricultor sem empregados, bóia fria, criador de animais (gado, porcos, galinhas, ovelhas, cavalos etc.), apicultor, pescador, lenhador, seringueiro, extrativista.
  - B – Grupo 2: Diarista, empregado doméstico, cuidador de idosos, babá, cozinheiro em casas particulares, motorista particular, jardineiro, faxineiro de empresas e prédios, vigilante, porteiro, carteiro, office-boy, vendedor, caixa,

atendente de loja, auxiliar administrativo, recepcionista, servente de pedreiro, repositor de mercadoria.

- C – Grupo 3: Padeiro, cozinheiro industrial ou em restaurantes, sapateiro, costureiro, joalheiro, torneiro mecânico, operador de máquinas, soldador, operário de fábrica, trabalhador da mineração, pedreiro, pintor, eletricista, encanador, motorista, caminhoneiro, taxista.
- D – Grupo 4: Professor (ensino fundamental/médio, idiomas, música, artes etc.), técnico (enfermagem, contabilidade, eletrônica etc.), policial, militar de baixa patente (soldado, cabo, sargento), corretor de imóveis, supervisor, gerente, mestre de obras, pastor, microempresário (menos de 10 empregados), pequeno comerciante, pequeno proprietário de terras, trabalhador autônomo.
- E – Grupo 5: Médico, engenheiro, dentista, psicólogo, economista, advogado, juiz, promotor, defensor, delegado, tenente, capitão, coronel, professor universitário, diretor de empresas públicas ou privadas, político, proprietário de empresas com mais de 10 empregados.
- F – Não sei.

• **Q004**: Grupo ocupacional da mãe ou mulher responsável.

- A – Grupo 1: Lavradora, agricultora sem empregados, bóia fria, criadora de animais (gado, porcos, galinhas, ovelhas, cavalos etc.), apicultora, pescadora, lenhadora, seringueira, extrativista.
- B – Grupo 2: Diarista, empregada doméstica, cuidadora de idosos, babá, cozinheira em casas particulares, motorista particular, jardineira, faxineira de empresas e prédios, vigilante, porteira, carteira, office-boy, vendedora, caixa, atendente de loja, auxiliar administrativa, recepcionista, servente de pedreiro, repositora de mercadoria.
- C – Grupo 3: Padeira, cozinheira industrial ou em restaurantes, sapateira, costureira, joalheira, torneira mecânica, operadora de máquinas, soldadora, operária de fábrica, trabalhadora da mineração, pedreira, pintora, eletricista, encanadora, motorista, caminhoneira, taxista.
- D – Grupo 4: Professora (ensino fundamental/médio, idiomas, música, artes etc.), técnica (enfermagem, contabilidade, eletrônica etc.), policial, militar de baixa patente, corretora de imóveis, supervisora, gerente, mestre de obras, pastora, microempresária (menos de 10 empregados), pequena comerciante, pequena proprietária de terras, trabalhadora autônoma.
- E – Grupo 5: Médica, engenheira, dentista, psicóloga, economista, advogada, juíza, promotora, defensora, delegada, tenente, capitã, coronel, professora

universitária, diretora em empresas públicas ou privadas, política, proprietária de empresas com mais de 10 empregados.
  - F – Não sei.

- **Q005**: Incluindo o participante, número de pessoas que moram na residência.
  - 1 – 1 (mora sozinho(a))
  - 2 – 2
  - 3 – 3
  - 4 – 4
  - 5 – 5
  - 6 – 6
  - 7 – 7
  - 8 – 8
  - 9 – 9
  - 10 – 10
  - 11 – 11
  - 12 – 12
  - 13 – 13
  - 14 – 14
  - 15 – 15
  - 16 – 16
  - 17 – 17
  - 18 – 18
  - 19 – 19
  - 20 – 20

- **Q006**: Renda mensal familiar.
  - A – Nenhuma renda
  - B – Até R$ 1.045,00
  - C – De R$ 1.045,01 até R$ 1.567,50
  - D – De R$ 1.567,51 até R$ 2.090,00
  - E – De R$ 2.090,01 até R$ 2.612,50
  - F – De R$ 2.612,51 até R$ 3.135,00

  - G – De R$ 3.135,01 até R$ 4.180,00
  - H – De R$ 4.180,01 até R$ 5.225,00
  - I – De R$ 5.225,01 até R$ 6.270,00
  - J – De R$ 6.270,01 até R$ 7.315,00
  - K – De R$ 7.315,01 até R$ 8.360,00
  - L – De R$ 8.360,01 até R$ 9.405,00
  - M – De R$ 9.405,01 até R$ 10.450,00
  - N – De R$ 10.450,01 até R$ 12.540,00
  - O – De R$ 12.540,01 até R$ 15.675,00
  - P – De R$ 15.675,01 até R$ 20.900,00
  - Q – Acima de R$ 20.900,00
- **Q007**: Presença de empregado(a) doméstico(a) na residência.
  - A – Não
  - B – Sim, um ou dois dias por semana
  - C – Sim, três ou quatro dias por semana
  - D – Sim, pelo menos cinco dias por semana
- **Q008**: Banheiro na residência.
  - A – Não
  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q009**: Quartos para dormir na residência.
  - A – Não
  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q010**: Carros na residência.
  - A – Não

  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q011**: Motocicletas na residência.
  - A – Não
  - B – Sim, uma
  - C – Sim, duas
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q012**: Geladeiras na residência.
  - A – Não
  - B – Sim, uma
  - C – Sim, duas
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q013**: Freezer (independente ou segunda porta da geladeira).
  - A – Não
  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q014**: Máquina de lavar roupa (não considerar tanquinho).
  - A – Não
  - B – Sim, uma
  - C – Sim, duas
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q015**: Máquina de secar roupa.

  - A – Não
  - B – Sim, uma
  - C – Sim, duas
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q016**: Forno micro-ondas na residência.
  - A – Não
  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q017**: Máquina de lavar louça na residência.
  - A – Não
  - B – Sim, uma
  - C – Sim, duas
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q018**: Aspirador de pó na residência.
  - A – Não
  - B – Sim
- **Q019**: Televisão em cores na residência.
  - A – Não
  - B – Sim, uma
  - C – Sim, duas
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q020**: Aparelho de DVD na residência.
  - A – Não
  - B – Sim

- **Q021**: TV por assinatura na residência.
  - A – Não
  - B – Sim
- **Q022**: Telefone celular na residência.
  - A – Não
  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q023**: Telefone fixo na residência.
  - A – Não
  - B – Sim
- **Q024**: Computador na residência.
  - A – Não
  - B – Sim, um
  - C – Sim, dois
  - D – Sim, três
  - E – Sim, quatro ou mais
- **Q025**: Acesso à internet na residência.
  - A – Não
  - B – Sim